

3D-TBP를 활용한 피부암 탐지 알고리즘

CUAI 7기 CV 4팀

오규안(AI학과), 최시우(AI학과), 정성룡(AI학과)

* 위 저자들은 본 연구에 동일하게 기여함.

[요약] 본 연구는 피부암 진단을 위해 이미지 데이터와 ABCD 규칙을 반영한 정형 데이터를 결합한 통합 모델을 제안한다. 딥러닝과 부스팅 기반 머신러닝 기법을 활용해, 정형 데이터와 이미지 피처를 결합하여 높은 예측 정확도를 달성하였다. 특히, 기존의 연구와 비교하여, 통합 접근법이 우수한 성능을 보임을 확인하였으며, 이는 피부암 조기 진단에서의 실용성을 입증한다.

1. 서론

피부암은 조기에 발견되지 않으면 치명적일 수 있는 질병이다. 조기 발견과 치료는 피부암의 생존율을 크게 향상시킬 수 있지만, 많은 사람들이 전문적인 피부과 진료를 받지 못해, 적시에 피부암을 발견하지 못하는 상황이 빈번하다. 이러한 문제는 특히 의료 자원이 제한된 지역에서 더욱 심각하다.

최근 들어, 인공지능(AI) 기술이 의료 진단 분야에 큰 혁신을 가져오고 있다. 특히, AI 기반 이미지 분석 기술은 피부암과 같은 시각적 증상을 동반하는 질병의 진단에 있어서 매우 유용하다. 이에 따라, 휴대폰 사진과 유사한 낮은 품질의 이미지를 통해, 피부암을 구별할 수 있는 AI 알고리즘의 개발이 중요한 과제로 떠오르고 있다. 이러한 문제를 해결하기 위해, 우리는 이미지뿐만 아니라 병변의 특징과 환자 정보를 포함한 정형 데이터를 함께 학습하여, 보다 정확한 진단을 도모하는 AI 모델을 개발하고자 한다.

본 논문에서는 이미지 데이터와 정형 데이터를 통합하여 AI 모델을 설계하고 훈련하는 과정을 상세히 설명할 것이다. 또한, 개발된 모델의 성능 평가와 한계점에 대해 논의할 것이다. 이를 통해, 피부암 조기 진단을 위한 AI 기술의 가능성과 향후 발전 방향을 제시하고자 한다.

2. 본론

I. 관련 내용

1) ABCD 규칙

ABCD 규칙은 사람들이 피부암의 잠재적 징후를 발견하도록 돕는 규칙이다. ABCD 규칙의 각 요소는 다음과 같다. 비대칭 (Asymmetry): 악성 반점이나 점의 절반은 반을 나누었을 때, 다른 절반과 일치하지 않는 경우가 많다. 악성이 아닌 점은 일반적으로 대칭적이어서 좌우가 거의 동일하다. 경계 (Border): 악성 반점이나 점의 경계는 불규칙하거나 흐리며, 때로는 분홍색이나 빨간색을 띌 수 있다. 반면에 악성이 아닌 반점이나 점의 경계는 대체로 명확하고 일정하다. 색 (Color): 일반적인 점은 주로 단일 갈색 음영으로 균일하게 색칠되어 있다. 반면에 악성 반점은 여러 색상의 음영을 가질 수 있으며, 황갈색, 갈색, 검정색 외에도 흰색, 빨간색 또는 파란색을 포함할 수 있다. 직경 (Diameter): 반점이나 점의 지름이 6mm 이상이면 경고 신호일 수도 있다. ABCD 규칙은 간단하지만 효과적인 도구로, 많은 사람들이 이를 통해 피부 상태를 쉽게 점검한다. 따라서, 위 규칙을 적용하여 이미지 피처를 만들어냈다.

II. 연구 방법

1) 모델 구조

본 연구에서는 피부암 진단을 위해 이미지 데이터와 정형 데이터라는 두 가지 모달리티를 결합하여 통합된 예측 모델을 개발하였다. 먼저 딥러닝 모델을 활용해 이미지 데이터로부터 피처 벡터를 생성한 후, 이를 정형 데이터와 결합하여 부스팅(Boosting) 기법을 기반으로 한 머신러닝 모델에 학습시킨다(Figure 1). 이를 통해 피부암의 시각적 특성과 환자의 의학적 정보를 모두 고려한 예측 모델을 구성하였다.

또한, 기존의 접근법으로는 CNN(Convolutional Neural Network) 모델을 통해 이미지 데이터에서 피처를 추출하고, FFN(Fully Connected Feedforward Network)을 통해 정형 데이터에서 피처를 추출한 후, 두 가지 피처를 concat하여 이를 분류기(classifier)에

입력하는 방식으로 모델을 학습시킬 수 있다(Qishen Ha et al., 2020). 이러한 방법도 통합적인 진단 시스템을 구성하는 데 활용될 수 있으며, 다양한 데이터 소스를 결합하는 점에서 유용하다. 그러나 본 연구에서는 이미지 데이터뿐만 아니라 피부암 진단에서 중요한 "ABCD 규칙"을 반영하는 정형 데이터를 보다 효과적으로 처리하는 방법을 제안하였다.

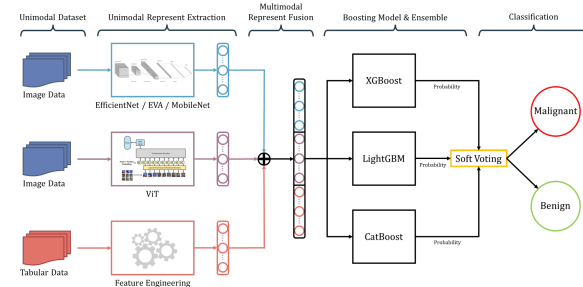


Figure 1. 피부암 진단 모델 구조

2) 데이터셋

본 연구에서는 ISIC 2024 - Skin Cancer Detection with 3D-TBP에서 제공하는 3D 전신 사진(3D-TBP)을 기반으로 한 피부암 데이터를 사용하였다. 해당 데이터셋은 음성 사례 400,666개와 양성 사례 393개로 구성되어 있으며, 상당한 불균형을 보이는 특성을 가진다.

Feature Engineering. 본 연구에서는 ABCD 규칙(Asymmetry, Border, Color, Diameter)을 기반으로 정형 데이터를 피쳐 엔지니어링하여, 머신러닝 모델이 더 나은 성능을 발휘할 수 있도록 하였다. ABCD 규칙을 활용한 피쳐 엔지니어링 과정에서는 병변의 비대칭성, 경계의 불규칙성, 색상의 변화, 직경 등의 중요한 피부암 특징을 정형 데이터로 효과적으로 표현하였다. 또한, 전처리된 정형 데이터를 딥러닝 기반으로 추출된 이미지 피쳐와 결합하여 최종 모델 학습에 활용하였다. 이와 같은 통합적 접근을 통해 시각적 정보와 임상적 정보를 함께 학습할 수 있었고, 이는 피부암 진단의 정확도 향상에 기여하였다.

3) 이미지처리

이미지 데이터로부터 효과적인 피쳐를 추출하기 위해, 본 연구에서는 두 가지 방법을 활용하였다. 첫 번째 방법은 딥러닝 모델의 최종 출력 결과를 피쳐로 사용하는 방식이다. 이 방법에서는 딥러닝 모델이 이미 학습한 전체적인 예측 결과를 피쳐로 활용한다. 두 번째 방법은 딥러닝 모델의 분류기(classifier) 이전 레이어에서 추출된 피쳐를 사용하는 방식이다. 이 방법은 모델이 이미지의 세부적인 특징을 학습하는 중간 레이어의 출력을 피쳐로 사용한다. 구체적으로, 첫 번째

방법에서는 EfficientNet V1과 EVA-02 모델을 사용하였고 두 번째 방법에서는 MobileNet V3 Large와 ViT Base 모델을 활용하였다.

4) 평가지표

평가지표로는 악성 사례의 이진 분류 성능을 평가하기 위해 **ROC(Receiver Operating Characteristic) 곡선 아래의 부분 면적(pAUC)**을 사용하였다. pAUC는 TPR(True Positive Rate)이 80%를 초과하는 구간에서의 AUC(Area Under the Curve)를 계산하는 방식으로, 이는 모델이 높은 민감도가 요구되는 구간에서 얼마나 정확하게 분류할 수 있는지를 평가하는 데 중점을 둔다.

III. 실험

1) 학습 설정

본 연구에서는 ABCD 규칙을 잘 반영하도록 전처리된 정형 데이터를 이미지 데이터로부터 추출한 피쳐 벡터와 결합하여 XGBoost, LightGBM, CatBoost 3개의 부스팅(Boosting)기법을 기반으로 한 머신러닝 모델을 통해 학습시켰다.

Oversampling and Undersampling. ISIC 2024 - Skin Cancer Detection with 3D-TBP 데이터셋은 상당히 불균형한 특성을 지니고 있어, 모델의 학습 과정에서 데이터 불균형을 해결하기 위한 방법을 적용하였다. 음성 클래스에 대한 undersampling을 통해 클래스 불균형으로 인한 모델의 편향을 줄이고 양성 클래스에 대한 oversampling을 통해 충분한 학습 데이터를 확보하였다. 이러한 샘플링 기법을 통해 모델의 예측 성능을 향상시키고, 불균형한 데이터 환경에서도 안정적인 피부암 진단 결과를 도출할 수 있도록 하였다.

2) 이미지 증강 및 학습

본 연구에서는 양성 데이터의 수가 적어 학습 데이터에 과적합(overfitting)이 발생할 가능성이 높기 때문에 이를 방지하고 모델의 일반화 성능을 향상시키기 위해 다양한 이미지 증강 기법을 적용하였다. 구체적으로 사용된 이미지 증강 기법은 RandomRotate90, Flip, Downscale, ShiftScaleRotate, HueSaturationValue, RandomBrightnessContrast이 포함되며, 이를 통해 모델이 보다 강건하게 학습될 수 있도록 하였으며, 과적합을 효과적으로 방지할 수 있었다.

학습 과정에서는 EVA, EfficientNet, MobileNet, ViT 모델을 활용하였으며, 모두 사전 학습된 모델을 기반으로 하였다.

학습에는 Adam 최적화 알고리즘이 사용되었으며, 학습률은 $1e-4$ 로 설정되었다. 총 50 epoch 동안 모델을 학습시켰으며, 학습 과정 중에는 Validation 데이터셋에서 pAUC가 가장 높은 모델을 체크포인트로 저장하였다. 이 저장된 최적의 모델은 이후 이미지 데이터에서 피쳐 벡터를 생성하는 데 사용되었으며, 해당 피쳐 벡터들은 부스팅 기반의 머신러닝 모델에 입력되어 최종적인 피부암 진단에 활용되었다.

3) Boosting 기반 모델 학습

전처리된 정형 데이터와 딥러닝 모델에서 추출한 이미지 피쳐 벡터를 결합하여, 부스팅 기반의 머신러닝 모델(XGBoost, LightGBM, CatBoost)을 통해 학습을 진행하였다. 하이퍼파라미터 튜닝 과정에서는 Optuna를 사용하였다. Optuna는 효율적인 하이퍼파라미터 탐색을 가능하게 하며, 이를 통해 각 부스팅 모델의 성능을 최적화하였다. 최적화된 하이퍼파라미터를 적용한 모델들은 개별적으로 학습된 후, 예측 단계에서 soft voting 방식을 사용하여 앙상블하였다. Soft voting은 각 모델이 출력한 클래스 확률의 평균을 계산하여 최종 예측을 결정하는 방식으로, 여러 모델의 예측 결과를 결합함으로써 보다 안정적이고 향상된 성능을 도출할 수 있다.

4) Ablation Study 이 섹션에서는 본 연구에서 제안한 모델의 각 요소가 전체 성능에 미치는 영향을 분석하기 위해 Ablation Study를 수행하였다. 구체적으로, 이미지 피쳐 추가, 샘플링 기법, 그리고 앙상블 전략의 효과를 분석하였으며, 이를 통해 각 요소의 중요성을 평가하였다. Table 1에서는 각 요소를 순차적으로 제거했을 때의 성능 변화를 확인할 수 있다. 이미지 피쳐를 제거했을 때 성능이 크게 저하되는 것을 확인할 수 있었는데, 이는 이미지 데이터를 통한 시각적 정보가 피부암 판별에 중요한 기여를 한다는 것을 시사한다. 또한, 샘플링 기법과 앙상블 역시 모델 성능에 중요한 영향을 미쳤으며, 이들의 제거 또한 성능 저하를 유발하였다. 이는 특히 불균형한 데이터셋에서 샘플링 기법이 데이터의 균형을 맞추어주는 역할을 하고, 앙상블 기법이 개별 모델의 약점을 보완하여 더 강력한 분류 성능을 달성할 수 있음을 나타낸다. 결과적으로, 본 연구에서 제안한 모델의 모든 요소가 결합되었을 때 가장 우수한 성능을 보였으며, 이는 피부암 진단을 위한 통합적인 접근이 효과적임을 확인할 수 있었다.

Table 1: Ablation Study

Ablation	Variation on pAUC
No Ablation	0.183

이미지 피쳐 제거	0.179 (-0.04)
샘플링 제거	0.179 (-0.04)
only XGBoost	0.176 (-0.06)
only LightGBM	0.180 (-0.03)
only CatBoost	0.175 (-0.08)

3. 결 론

피부암을 판별하는 과정에서, 기존의 의학적 정보를 활용하여 피부암과 관련된 데이터를 정형화하고, ABCD 규칙에 기반한 피쳐 엔지니어링을 수행하는 것의 중요성을 알 수 있다. 이와 함께, 이미지 데이터를 딥러닝 모델을 통해 분석하여 피부암 진단에 활용하는 접근법도 매우 중요하다. 이러한 두 가지 접근법은 상호 보완적이며, 각각의 강점을 결합함으로써 진단의 정확도를 크게 향상시킬 수 있다.

본 연구는 기존의 연구(Qishen Ha et al., 2020)와 비교하여, 기존의 의학적 정보를 바탕으로 생성된 정형 데이터와 이미지에서 딥러닝 모델을 통해 추출한 피쳐를 결합하여, 부스팅 기반의 모델에 학습시킬 경우 더욱 우수한 성능을 발휘할 수 있음을 확인하였다[Table 2]. 이러한 결합 방식은 단순히 정형 데이터나 이미지 피쳐를 개별적으로 사용하는 것보다, 두 정보를 통합하여 모델에 학습시킬 때 더 나은 예측 정확도를 달성할 수 있게 한다.

Table 2: 기존 연구(Qishen Ha et al., 2020)의 접근법과 본 연구의 접근법의 모델 pAUC 비교

Model	pAUC
CNN + FFN concat	0.151
DL + Boosting	0.183

참고 문헌

[1] Qishen Ha, Bo Liu, and Fuxu Liu. Identifying Melanoma Images using EfficientNet Ensemble: Winning Solution to the SIIM-ISIC Melanoma Classification Challenge. arXiv preprint arXiv:2010.05351, 2020.