

반도체 웨이퍼 데이터 증강에 따른 CNN 모델 성능 평가

박성호(전자전기공학부), 박준상(전자전기공학부), 양지훈(전자전기공학부),
조효원(전자전기공학부), 황지민(전자전기공학부)



2024 CUA이 중앙대학교 인공지능 학회 하계 컨퍼런스
Proceeding of 2024 Chung-Ang University Artificial Intelligence Summer Conference

Abstract

반도체 제조 공정의 높은 정밀성과 비용 때문에, 실시간 불량 예측과 신속한 대응이 필수적이다. 본 연구는 웨이퍼 데이터를 활용하여 불량 유무와 유형을 예측하고 맞춤형 대응을 가능하게 하는 모델을 제안한다. 데이터 부족을 극복하기 위해 원본,정규분포 증강, GAN 생성 데이터를 비교하여 예측 정확도를 평가했다. 불량 발생을 최소화하고 생산 효율성을 높여 반도체 제조 공정의 비용 절감을 실현할 수 있는 방안을 제시한다

Introduction

반도체 제조 공정에서 생성되는 웨이퍼 빈 맵(WBM)은 결함 패턴을 시각적으로 확인하고 결함 원인을 파악하는 데 중요하다. 숙련된 기술자가 육안으로 분석하는 방식은 시간과 비용이 많이 소요되며 생산량이 증가함에 따라 정확한 분석을 유지하는 것이 점점 어려워진다.

CNN기반의 모델이 WBM의 결함 패턴 분류에 효과적으로 활용되고 있지만 성능은 훈련 데이터의 양과 질에 크게 의존하며, 데이터의 불균형 문제와 데이터 부족 상황에서는 예측 정확도와 일반화 능력이 저하될 수 있다.해당 문제를 데이터의 증강을 통해 해결하여 하며 그 방법으로는 정규분포 증강과 GAN을 통한 증강을 사용한다.

Aim

본 연구는 WM-811K 데이터셋을 사용하여 반도체 제조 공정에서 발생하는 다양한 결함 패턴을 분석하고, 이를 분류하는 모델을 개발하는 것을 목표로 한다. 811,457개의 웨이퍼 맵으로 구성되어 있으며, 8가지 결함 패턴으로 라벨링된 데이터의 불균형이 문제로 지적된다. 이는 모델의 성능에 영향을 미치고, 이를 해결하기 위해 데이터 증강 등의 방법이 필요하다.


Methods

AutoEncoder는 입력 데이터를 잠재 공간으로 압축하고 복원하는 비지도 학습 모델로, 본 연구는 Convolutional AutoEncoder(CAE)를 사용해 웨이퍼 데이터의 증강을 진행했다. CAE는 이미지의 주요 특징을 잠재 벡터로 인코딩한 후, 노이즈를 추가하여 변형된 데이터를 생성한다.


GAN은 생성자와 판별자라는 두 개의 신경망이 상호 경쟁적으로 학습하는 생성 모델로, 생성자는 실제 데이터와 유사한 가짜 데이터를 생성하며, 판별자는 실제 데이터와 가짜 데이터를 구별하는 역할을 한다.

두가지 GAN을 통해 증강을 진행하였다.DCGAN은 CNN의 특징 추출 능력을 활용하여 더욱 정교한 이미지를 생성하고 CGAN은 GAN에 조건을 추가하여 특정 조건에 맞는 데이터를 생성할 수 있도록 확장된 모델이다. 제어 가능한 이미지 생성이라는 CGAN의 장점으로 CGAN을 통한 증강을 진행했다.


불균형이 심한 원본데이터, CAE로 증강한 데이터, 그리고 CGAN으로 증강한 데이터를 활용하여 모델 성능을 평가했다. 동일한 CNN 모델을 적용해 각 모델의 데이터 증강 성능을 비교했으며, 모든 결함 패턴에 대해 고른 성능을 평가할 수 있도록 정확도 (Accuracy)를 CNN의 성능 평가 지표로 사용했다. 이를 통해 데이터 증강이 모델 성능에 미치는 영향을 확인하고, 불균형 문제를 해결하는 데 얼마나 효과적인지 평가했다.



원본 데이터



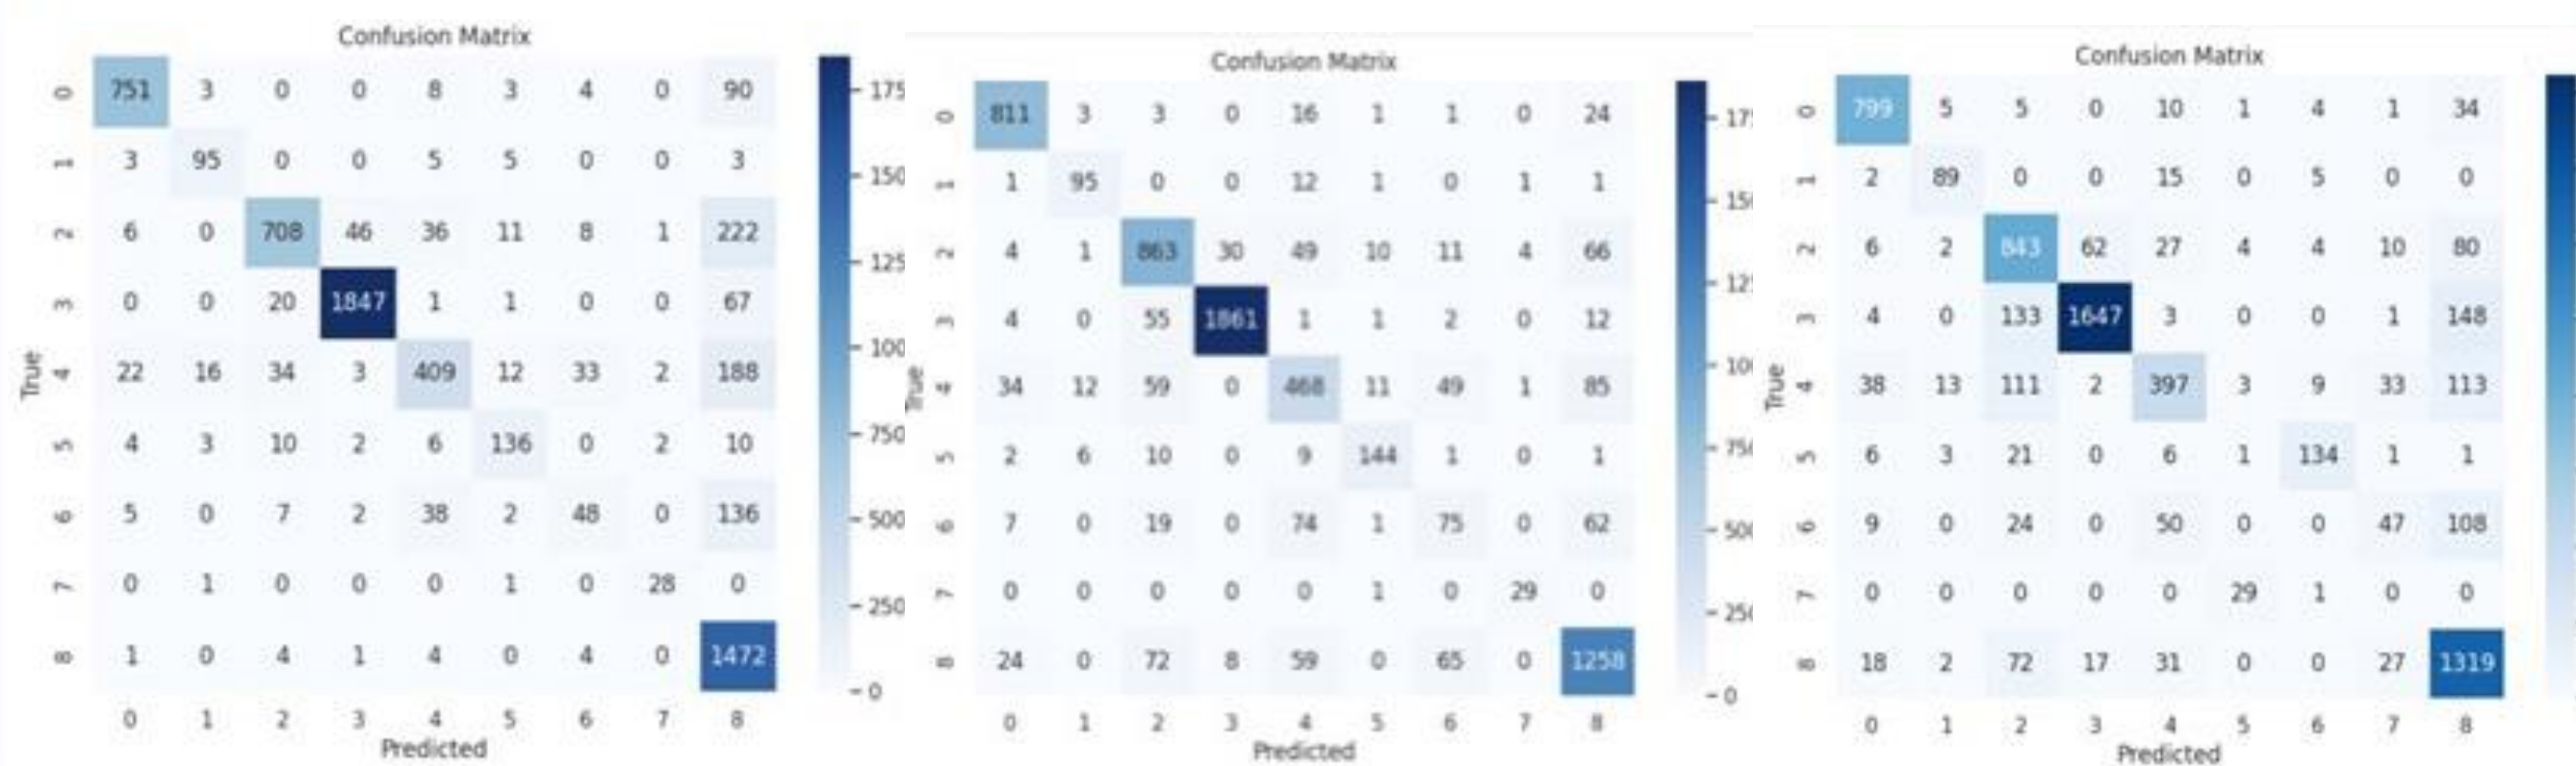
CAE 증강 데이터



CGAN 증강 데이터

Results

본 연구에서 설계한 CNN 모델은 Wafer 이미지의 특징을 효과적으로 추출하면서도 계산 복잡도를 줄이기 위해 비교적 경량화된 구조로 설계되었다. CNN 모델 학습에는 Adam Optimizer와 Cross-Entropy 손실 함수를 사용하였으며, K-Fold 교차 검증을 통해 정확도를 향상시켰다. 이를 바탕으로 CNN 성능 평가를 진행한 결과는 다음과 같다. 원본 데이터의 Accuracy는 83.37%, CAE로 증강한 데이터는 85.04%, CGAN으로 증강한 데이터는 77.47%로 나타났다.



원본 데이터

CAE 증강 데이터

CGAN 증강 데이터

Conclusion

Confusion Matrix를 통해 분석한 결과, CAE는 비교적 효과적인 증강을 보여주었지만, CGAN은 모드 붕괴(Mode Collapse) 현상으로 인해 복잡한 결함 패턴을 생성하는 데 어려움을 겪어 성능이 상대적으로 낮았다. 추후에 Binary Cross-Entropy 대신 Wasserstein Loss와 같은 손실 함수를 적용하는 방향으로 개선이 기대된다.

Reference

- Sung Jin Hwang,Insung Baek,Seoung Bum Kim
Department of Industrial and Management Engineering, Korea University, "Active Learning for Detecting New Defect Patterns in Wafer Bin Maps", Journal of the Korean Institute of Industrial Engineers, 2022.04
- 박인영, 김지영, "데이터 클래스 불균형을 고려한 전이학습 기반의 반도체 웨이퍼 빈 맵 결함 패턴 분류", Journal of the Korea Academia-Industrial cooperation Society, 2024년 5월 31일
- Chollet, François, et al. "Conditional GAN Example." *Keras*. Last modified 2024. https://keras.io/examples/generative/conditional_gan/
- Arjovsky, Martin, Soumith Chintala, and Léon Bottou. "GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium.". 2017 *arXiv*. <https://arxiv.org/abs/1701.07875>.